

1. Цель и данные

Проект: поиск мошенничества в мобильных переводах.

Объём: 50 000 транзакций.

Распределение: ~68% честные, ~32% мошеннические. Дисбаланс умеренный, модель не будет игнорировать фрод автоматически, но требует внимания к порогам.

2. Качество и подготовка данных

- Пропусков и дубликатов: 0.
- Время разобрали на понятные признаки: hour, day_of_week, is_night.
- Категории (Location, Merchant_Category и т.д.) превратили в числа 0/1.
- Суммы логарифмировали ($\log_{10}$), чтобы крупные переводы не ломали масштаб.
- Удалили Transaction_ID, User_ID, Timestamp и Risk_Score, чтобы модель не «подглядывала» в ответ или уникальные номера.

3. Гипотезы и статистика

Проверили 3 идеи графиками и тестами:

- KS-тест по частоте операций и средним суммам: $p > 0.6 \rightarrow$ изолированно эти признаки не разделяют классы.
- Корреляция Пирсона по количеству сбоев за 7 дней: $r \approx 0.51$, $p < 0.0001 \rightarrow$ это самый сильный одиночный сигнал.


Вывод: ни один признак не работает идеально сам по себе. Главная сила раскроется в комбинациях, поэтому переходим к ансамблевым моделям.

4. Модели и настройка

- LogisticRegression (базовая): Recall ≈ 0.82 , Precision ≈ 0.66 . Ловит много фрода, но даёт ложные тревоги.
- RandomForest + Optuna: улучшил стабильность на валидации (CV F1: $0.72 \rightarrow 0.76$), но на тесте метрики остались похожими. Модели уперлись в потолок текущих данных.

Вывод: гиперпараметры настроены, дальше оптимизируем не модель, а порог принятия решения.

Сравнение моделей: Бизнес-баланс и Эффективность



Визуальный анализ:

- **Logistic Regression:** Показывает умеренный Recall (0.85), но обеспечивает приемлемую Precision и самую низкую стоимость ошибок (750K ₮). Это "золотая середина" для банка.
- **Random Forest (Optuna):** Достигает наивысшего Recall (0.90) и F1, но ценой критического падения Precision и удвоения финансовых потерь (1.5M ₮) из-за ложных срабатываний.

Итог: Несмотря на более высокий F1 у Random Forest, для бизнеса выгоднее первая модель.

5. Пороги и бизнес-логика

Модель	Порог	Precision	Recall	FP	FN	Cost (тг)
Logistic Regression	0.35	0.68	0.85	~1200	~450	~750 000
Optuna-tuned RF	0.19	0.37	0.90	5025	310	1 566 250

Сдвинули порог у RF вниз до 0.19, чтобы поймать 90% фрода (Recall = 0.90). Но ложных блокировок стало >5000, и общая стоимость ошибок выросла до ~1.5 млн тг. Оказалось, LogisticRegression с порогом ~0.35 выгоднее (~750 тыс. тг) при тех же весах (FN=1000 тг, FP=250 тг).

Итоговое решение: для текущих бизнес-условий оптимальна линейная модель с порогом ~ 0.35 или RF с дополнительной ручной проверкой «серой зоны» (вероятности 0.3–0.6).