

Промежуточный отчёт: Проект «Детекция мошеннических транзакций в мобильных переводах»

1. Цель проекта и источник данных

Проект направлен на разработку модели выявления мошеннических транзакций в мобильных переводах. Задача сформулирована с учётом бизнес-асимметрии: пропуск мошенника (False Negative) стоит дороже, чем ложная блокировка честного клиента (False Positive).

Датасет: Публичный набор данных «**synthetic_fraud_dataset**» с Kaggle, содержащий **50 000** записей о мобильных платежах. Целевая переменная **Fraud_Label** имеет умеренный дисбаланс: 67,87% честных транзакций, 32,13% мошеннических.

2. Структура и качество данных

Датасет содержит 21 признак: Идентификаторы, временные метки (Timestamp), финансовые объёмы, агрегированную активность за 7 дней (Daily_Transaction_Count, Avg_Transaction_Amount_7d, Failed_Transaction_Count_7d), контекст (Location, Merchant_Category, IP_Address_Flag, Authentication_Method) и исторические флаги (Previous_Fraudulent_Activity, Card_Age).


Проверка качества:

- Пропусков: 0
- Дубликатов строк: 0
- Временные метки переведены в datetime, извлечены hour, day_of_week, is_night.
- Категориальные признаки (Authentication_Method, Merchant_Category, Location) закодированы для дальнейшего обучения. Финансовые суммы лог-трансформированы (log1p) для сглаживания тяжёлых хвостов распределения.

3. Результаты EDA и проверенные гипотезы

На основе первичного анализа сформулированы и визуализированы 3 гипотезы:

1. **Время + частота:** При Is_Weekend=True и высоком Daily_Transaction_Count доля фрода растёт.



Результат: Изолированно не подтверждена (разница в долях $< 1.5\%$).
Признак эффективен только в комбинации.


2. **Флаг IP:** Активный IP_Address_Flag коррелирует с фродом.



Результат: Подтверждена умеренно ($\sim 32,8\%$ vs $\sim 32,1\%$). Будет использоваться как вспомогательный сигнал.

3. Скачок активности: Резкий рост количества операций при стабильной средней сумме за 7 дней указывает на аномалию.

Доля мошеннических транзакций в зависимости от частоты операций за день



Результат: Частично подтверждена. На lineplot видно смещение красных точек в зону высоких значений, но перекрытие с честными транзакциями велико. Изолированное пороговое правило даёт умеренный Recall при низком Precision.

3.2. Статистическое подтверждение

Для проверки значимости различий распределений применен критерий Колмогорова-Смирнова (KS-test), а для оценки линейной связи — корреляция Пирсона (уровень значимости $\alpha=0.05$):

- **KS-test (Daily_Transaction_Count):** p-value = **0.6668**, D = **0.0069**. Распределение частоты операций статистически не различимо между честными и мошенническими транзакциями. Изолированно признак не является маркером риска.

- **KS-test (Avg_Transaction_Amount_7d):** p-value = **0.7692**, D = **0.0063**. Средние объёмы транзакций также не демонстрируют значимого разделения. Это подтверждает, что финансовые суммы сами по себе не определяют уровень риска.

- **Корреляция Пирсон (Failed_Transaction_Count_7d):** p-value < **0.0001**, $r =$ **0.5099**. Выявлена статистически значимая умеренно-сильная положительная связь. Признак демонстрирует высокую предсказательную силу и будет использован как один из ключевых индикаторов в модели.

Вывод статистики: Анализ выявил явного лидера среди изолированных признаков — количество сбоев за 7 дней. Остальные метрики (count, amount) будут эффективны только в комбинации с контекстом, что обосновывает выбор нелинейных ансамблевых моделей (RandomForest/XGBoost) и этап Feature Engineering для создания комбинированных индикаторов риска.

Вывод EDA: Изолированные признаки не дают чёткого разделения классов. Прогнозируется, что основная предсказательная сила раскроется при совместном использовании признаков в ансамблевых моделях, способных улавливать нелинейные взаимодействия.

4. План моделирования и ожидаемые метрики

- **Разделение данных:** Хронологический сплит (train = первые 80% по времени, test = последние 20%) для исключения утечки временных паттернов.
- **Модели:** Baseline (LogisticRegression) → RandomForest / XGBoost → настройка гиперпараметров (Optuna).
- **Метрики оценки:** Основной ориентир — Precision-Recall кривая и F1-score. Приоритет дан Recall из-за бизнес-асимметрии ошибок.
- **Ожидаемые ориентиры:** $\text{Recall} \geq 0.80$, $\text{Precision} \geq 0.70$, $\text{F1} \approx 0.75$. Порог срабатывания будет подобран вручную по кривой компромисса между FN и FP.

5. Следующие шаги до Demo Day

1. Создание комбинированных признаков (user_frequency_deviation, failed_attempts_ratio, auth_level × amount_deviation).
2. Обучение и сравнение моделей, настройка гиперпараметров.
3. Оценка стабильности распределений на тесте (PSI/KS для ключевых признаков).
4. Упаковка лучшей модели в простой интерфейс (Docker) для демонстрации.
5. Подготовка презентации: фокус на бизнес-логике порога, валидации и реалистичных метриках.